

Lezione : Analisi fattoriale

Docente: Aldo Solari

Nelle scienze sociali, in particolare in psicologia, spesso è problematico misurare le variabili di interesse direttamente. Ad esempio:

- Intelligenza
- Classe sociale

Queste variabili non osservabili (variabili latenti) sono chiamate *fattori comuni*. E' possibile esaminare queste variabili indirettamente, misurando variabili osservabili che sono ad esse collegate. Ad esempio

- Punteggio in varie prove di intelligenza, etc.
- Occupazione, Tasso di istruzione, Casa di proprietà, etc.

L'obiettivo dell'*analisi fattoriale* è studiare le relazioni tra variabili osservabili e fattori comuni

1 Il modello fattoriale con k fattori

$$\begin{aligned}x_1 &= \lambda_{11}f_1 + \dots + \lambda_{1k}f_k + u_1 \\x_2 &= \lambda_{21}f_1 + \dots + \lambda_{2k}f_k + u_2 \\&\vdots \\x_p &= \lambda_{p1}f_1 + \dots + \lambda_{pk}f_k + u_p\end{aligned}$$

dove

- $x_{p \times 1} = (x_1, \dots, x_p)'$ sono le *variabili osservate* (variabili casuali)
- $f_{k \times 1} = (f_1, \dots, f_k)'$ sono i *fattori comuni* (var. casuali non oss.)
- $u_{p \times 1} = (u_1, \dots, u_p)'$ sono i *fattori specifici* (var. casuali non oss.)
- λ_{ij} sono i *pesi fattoriali* (costanti incognite)

In forma matriciale:

$$x_{p \times 1} = \Lambda_{p \times k} f_{k \times 1} + u_{p \times 1}$$

1.1 Assunzioni

1. Variabili osservate: $\mathbb{E}(\underset{p \times 1}{x}) = \underset{p \times 1}{0}$ (altrimenti centrare sullo 0)
2. Fattori comuni: $\mathbb{E}(\underset{k \times 1}{f}) = \underset{k \times 1}{0}$, $\mathbb{Cov}(\underset{k \times 1}{f}) = \mathbb{E}(\underset{k \times 11 \times k}{f f'}) = \underset{k \times k}{I}$
3. Fattori specifici: $\mathbb{E}(\underset{p \times 1}{u}) = \underset{p \times 1}{0}$, $\mathbb{Cov}(\underset{p \times 1}{u}) = \mathbb{E}(\underset{p \times 11 \times p}{u u'}) = \underset{p \times p}{\Psi} = \text{diag}(\psi_1, \dots, \psi_p)$
4. Incorrelazione tra f e u : $\mathbb{Cov}(\underset{p \times 1}{u}, \underset{k \times 1}{f}) = \mathbb{E}(\underset{p \times 11 \times k}{u f'}) = \underset{p \times k}{0}$

1.2 Proprietà

Proposition 1.1. La matrice di varianza/covarianza Σ di x è data da

$$\underset{p \times p}{\Sigma} = \underset{p \times k}{\Lambda} \underset{k \times p}{\Lambda'} + \underset{p \times p}{\Psi}$$

Dimostrazione.

$$\begin{aligned} \underset{p \times p}{\Sigma} &= \mathbb{Cov}(\underset{p \times 1}{x}) = \mathbb{E}(\underset{p \times 11 \times p}{x x'}) \\ &= \mathbb{E}[(\Lambda f + u)(\Lambda f + u)'] \\ &= \mathbb{E}[\Lambda f(\Lambda f)' + u(\Lambda f)' + (\Lambda f)u' + uu'] \\ &= \Lambda \mathbb{E}(f f') \Lambda' + \mathbb{E}(u f') \Lambda' + \Lambda \mathbb{E}(f u') + \mathbb{E}(u u') \\ &= \Lambda \mathbb{Cov}(f) \Lambda' + \mathbb{Cov}(u, f) \Lambda' + \Lambda \mathbb{Cov}(f, u) + \mathbb{Cov}(u) \\ &= \Lambda \Lambda' + \Psi \end{aligned}$$

□

Il modello fattoriale con k fattori ipotizza che

$$p(p+1)/2$$

parametri corrispondenti alle p varianze e alle $p(p-1)/2$ covarianze di $\underset{p \times p}{\Sigma}$ possano essere espressi con

$$p(k+1)$$

parametri corrispondenti ai pk pesi fattoriali di $\underset{p \times k}{\Lambda}$ e le p varianze specifiche di $\underset{p \times p}{\Psi}$.

Per esempio, se abbiamo $p = 12$ variabili osservabili $\underset{p \times 1}{x}$ e un modello fattoriale con $k = 2$ fattori, allora i $p(p+1)/2 = 78$ parametri di $\underset{p \times p}{\Sigma}$ possono essere ridotti ai $p(k+1) = 36$ parametri di $\underset{p \times k}{\Lambda}$ e $\underset{p \times p}{\Psi}$.

La varianza di x_i si può esprimere come

$$\begin{aligned}
 \sigma_{ii} &= \mathbb{V}\text{ar}(x_i) = \left\{ \Sigma \right\}_{p \times p} = \{\Lambda\Lambda'\}_{ii} + \{\Psi\}_{ii} \\
 &= \sum_{j=1}^k \lambda_{ij}^2 + \psi_i \\
 &= \underbrace{h_i^2}_{\text{comunalita'}} + \underbrace{\psi_i}_{\text{var. specifica}}
 \end{aligned}$$

dove

- $h_i^2 = \lambda_{i1}^2 + \dots + \lambda_{ik}^2$ è la comunalità, ovvero la varianza dovuta ai k fattori comuni
- ψ_i è la varianza specifica di x_i non attribuibile ai fattori comuni

La covarianza tra x_i e x_j si può esprimere come

$$\begin{aligned}
 \sigma_{ij} &= \mathbb{C}\text{ov}(x_i, x_j) = \left\{ \Sigma \right\}_{p \times p} = \{\Lambda\Lambda'\}_{ij} + \{\Psi\}_{ij} \\
 &= \sum_{l=1}^k \lambda_{il} \lambda_{jl} \\
 &= \lambda_{i1} \lambda_{j1} + \dots + \lambda_{ik} \lambda_{jk}
 \end{aligned}$$

La covarianza tra x e f si può esprimere come

$$\begin{aligned}
 \mathbb{C}\text{ov} \left(\begin{matrix} x \\ p \times 1 \end{matrix}, \begin{matrix} f \\ k \times 1 \end{matrix} \right) &= \mathbb{E} \left(\begin{matrix} x & f' \\ p \times 1 & 1 \times k \end{matrix} \right) \\
 &= \mathbb{E}[(\Lambda f + u)f'] \\
 &= \Lambda \mathbb{E}(ff') + \mathbb{E}(uf') \\
 &= \Lambda_{p \times k}
 \end{aligned}$$

quindi il peso fattoriale λ_{ij} rappresenta la covarianza tra x_i e f_j :

$$\mathbb{C}\text{ov}(x_i, f_j) = \left\{ \Lambda \right\}_{p \times k} = \lambda_{ij}$$

Example 1.2. Verifica della relazione $\Sigma = \Lambda\Lambda' + \Psi$ con $k = 2$

Example 9.1 (Verifying the relation $\Sigma = \Lambda\Lambda' + \Psi$ for two factors) Consider the covariance matrix

$$\Sigma = \begin{bmatrix} 19 & 30 & 2 & 12 \\ 30 & 57 & 5 & 23 \\ 2 & 5 & 38 & 47 \\ 12 & 23 & 47 & 68 \end{bmatrix}$$

The equality

$$\begin{bmatrix} 19 & 30 & 2 & 12 \\ 30 & 57 & 5 & 23 \\ 2 & 5 & 38 & 47 \\ 12 & 23 & 47 & 68 \end{bmatrix} = \begin{bmatrix} 4 & 1 \\ 7 & 2 \\ -1 & 6 \\ 1 & 8 \end{bmatrix} \begin{bmatrix} 4 & 7 & -1 & 1 \\ 1 & 2 & 6 & 8 \end{bmatrix} + \begin{bmatrix} 2 & 0 & 0 & 0 \\ 0 & 4 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 3 \end{bmatrix}$$

or

$$\Sigma = \mathbf{L}\mathbf{L}' + \Psi$$

may be verified by matrix algebra. Therefore, Σ has the structure produced by an $m = 2$ orthogonal factor model. Since

$$\mathbf{L} = \begin{bmatrix} \ell_{11} & \ell_{12} \\ \ell_{21} & \ell_{22} \\ \ell_{31} & \ell_{32} \\ \ell_{41} & \ell_{42} \end{bmatrix} = \begin{bmatrix} 4 & 1 \\ 7 & 2 \\ -1 & 6 \\ 1 & 8 \end{bmatrix},$$

$$\Psi = \begin{bmatrix} \psi_1 & 0 & 0 & 0 \\ 0 & \psi_2 & 0 & 0 \\ 0 & 0 & \psi_3 & 0 \\ 0 & 0 & 0 & \psi_4 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 0 & 0 \\ 0 & 4 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 3 \end{bmatrix}$$

the communality of X_1 is, from (9-6),

$$h_1^2 = \ell_{11}^2 + \ell_{12}^2 = 4^2 + 1^2 = 17$$

and the variance of X_1 can be decomposed as

$$\sigma_{11} = (\ell_{11}^2 + \ell_{12}^2) + \psi_1 = h_1^2 + \psi_1$$

or

$$\underbrace{19}_{\text{variance}} = \underbrace{4^2 + 1^2}_{\text{communality}} + \underbrace{2}_{\text{specific variance}} = 17 + 2$$

A similar breakdown occurs for the other variables. ■

1.3 Invarianza rispetto a trasformazioni di scala

Assumiamo il modello fattoriale per x :

$$x_{p \times 1} = \Lambda_{p \times k} f_{k \times 1} + u_{p \times 1}$$

Consideriamo una trasformazione di scala per x :

$$y_{p \times 1} = A_{p \times p} x_{p \times 1}$$

dove $A = \text{diag}(a_1, \dots, a_p)$ è una trasformazione di scala. Il modello fattoriale è ancora valido per y ? Abbiamo

$$\begin{aligned} y_{p \times 1} &= A_{p \times p} x_{p \times 1} \\ &= A_{p \times p} (\Lambda_{p \times k} f_{k \times 1} + u_{p \times 1}) \\ &= A_{p \times p} \Lambda_{p \times k} f_{k \times 1} + A_{p \times p} u_{p \times 1} \\ &= \Lambda_y f_{k \times 1} + u_y \end{aligned}$$

e

$$\begin{aligned} \text{Cov}(y) &= \text{Cov}(Ax) = A \text{Cov}(x) A' = A \Sigma A' \\ &= A \Lambda \Lambda' A' + A \Psi A' \\ &= \Lambda_y \Lambda_y' + \Psi_y \end{aligned}$$

quindi il modello fattoriale è ancora valido per y con pesi fattoriali $\Lambda_y = A\Lambda$ e varianze specifiche $\Psi_y = A\Psi A'$.

Il risultato precedente mostra che il modello fattoriale rimane essenzialmente inalterato se effettuiamo una trasformazione di scala. La standardizzazione

$$\underset{p \times 1}{z} = \underset{p \times p}{D}^{-1/2} \underset{p \times 1}{x}$$

è un caso particolare di trasformazione di scala dove

$$D^{-1/2} = \text{diag}(1/\sqrt{\sigma_{11}}, \dots, 1/\sqrt{\sigma_{pp}})$$

Questo significa che, invece di considerare la decomposizione della matrice di varianze/covarianze di x , $\text{Cov}(x)$, possiamo considerare la decomposizione della matrice di correlazione di x , $\text{Corr}(x)$, o equivalentemente, la decomposizione della matrice di varianze/covarianze di z , $\text{Cov}(z) = D^{-1/2}\Sigma D^{-1/2} = \text{Corr}(x)$.

Si noti che sebbene il modello fattoriale è invariante rispetto a trasformazioni di scala, la *stima* dei parametri potrebbe essere influenzata dalle trasformazioni di scala.

1.4 Non-unicità dei pesi fattoriali

Sia $\underset{k \times k}{A}$ una matrice ortogonale: $AA' = A'A = I$

$$\begin{aligned} \underset{p \times 1}{x} &= \underset{p \times k}{\Lambda} \underset{k \times 1}{f} + \underset{p \times 1}{u} \\ &= \underset{p \times k}{\Lambda} \underset{k \times k}{A} \underset{k \times 1}{A'} \underset{k \times 1}{f} + \underset{p \times 1}{u} \\ &= \underset{p \times k}{\Lambda^*} \underset{k \times 1}{f^*} + \underset{p \times 1}{u} \end{aligned}$$

- $\underset{p \times k}{\Lambda^*} = \underset{p \times k}{\Lambda} \underset{k \times k}{A}$
- $\underset{k \times 1}{f^*} = \underset{k \times k}{A'} \underset{k \times 1}{f}$
- $\mathbb{E}(f^*) = A' \mathbb{E}(f) = \underset{k \times 1}{0}$
- $\text{Cov}(f^*) = A' \text{Cov}(f) A = \underset{p \times p}{I}$
- $\text{Cov}(x) = \Sigma = \Lambda \Lambda' + \Psi = \Lambda A A' \Lambda' + \Psi = \Lambda^* \Lambda^{*'} + \Psi$

Il risultato precedente mostra che il modello fattoriale con fattori comuni $\underset{k \times 1}{f}$ e pesi fattoriali $\underset{p \times k}{\Lambda}$, e il modello fattoriale con fattori comuni $\underset{k \times 1}{f^*}$ e pesi fattoriali $\underset{p \times k}{\Lambda^*}$ sono equivalenti per spiegare la matrice di varianza/covarianza Σ di $\underset{p \times 1}{x}$.

2 Stima del modello fattoriale

Obiettivo: determinare due matrici $\hat{\Lambda}$ e $\hat{\Psi}$ tali che $\widehat{\mathbb{Cov}(x)} = \hat{\Sigma} = S = \hat{\Lambda}\hat{\Lambda}' + \hat{\Psi}$, oppure determinare due matrici $\hat{\Lambda}$ e $\hat{\Psi}$ tali che $\widehat{\mathbb{Corr}(x)} = R = \hat{\Lambda}\hat{\Lambda}' + \hat{\Psi}$

2.1 Stima naïve

Example 2.1. Si consideri il seguente esempio: sulla base di un campione di voti di studenti su tre materie, x_1 (Classics), x_2 (French) e x_3 (English) si è ottenuta la seguente matrice di correlazione:

$$\mathbf{R} = \begin{matrix} & \begin{matrix} \text{Classics} \\ \text{French} \\ \text{English} \end{matrix} \end{matrix} \begin{pmatrix} 1.00 & & \\ 0.83 & 1.00 & \\ 0.78 & 0.67 & 1.00 \end{pmatrix}.$$

Si consideri il modello fattoriale con $k = 1$ fattore

$$\begin{aligned} x_1 &= \lambda_1 f + u_1 \\ x_2 &= \lambda_2 f + u_2 \\ x_3 &= \lambda_3 f + u_3 \end{aligned}$$

Le sei equazioni derivanti dall'uguaglianza $R = \Lambda\Lambda' + \Psi$ sono

$$\mathbf{R} = \begin{pmatrix} \lambda_1 \\ \lambda_2 \\ \lambda_3 \end{pmatrix} (\lambda_1 \ \lambda_2 \ \lambda_3) + \begin{pmatrix} \psi_1 & 0 & 0 \\ 0 & \psi_2 & 0 \\ 0 & 0 & \psi_3 \end{pmatrix},$$

are

$$\begin{aligned} \hat{\lambda}_1 \lambda_2 &= 0.83, \\ \hat{\lambda}_1 \lambda_3 &= 0.78, \\ \hat{\lambda}_1 \lambda_4 &= 0.67, \\ \psi_1 &= 1.0 - \hat{\lambda}_1^2, \\ \psi_2 &= 1.0 - \hat{\lambda}_2^2, \\ \psi_3 &= 1.0 - \hat{\lambda}_3^2. \end{aligned}$$

The solutions of these equations are

$$\begin{aligned} \hat{\lambda}_1 &= 0.99, \quad \hat{\lambda}_2 = 0.84, \quad \hat{\lambda}_3 = 0.79, \\ \hat{\psi}_1 &= 0.02, \quad \hat{\psi}_2 = 0.30, \quad \hat{\psi}_3 = 0.38. \end{aligned}$$

Example 2.2. *Casi di Heywood*

Esempio 4 (tratto da Everitt e Dunn, 2001):

Si stimino i parametri del modello fattoriale ad un fattore per i punteggi ottenuti nelle tre materie:

x_1 : Classics, x_2 : French e x_3 : English.

$$x_1 = \lambda_1 f + u_1,$$

$$x_2 = \lambda_2 f + u_2,$$

$$x_3 = \lambda_3 f + u_3.$$

data la matrice di correlazione campionaria $R = \begin{matrix} & \begin{matrix} \text{Classics} & \text{French} & \text{English} \end{matrix} \\ \begin{matrix} \text{Classics} \\ \text{French} \\ \text{English} \end{matrix} & \begin{pmatrix} 1.00 & & \\ 0.84 & 1.00 & \\ 0.60 & 0.35 & 1.00 \end{pmatrix} \end{matrix}$

Si ottiene il sistema
$$\begin{aligned} \hat{\psi}_1 &= 1.0 - \hat{\lambda}_1^2, & \lambda_1 \lambda_2 &= 0.84 \\ \hat{\psi}_2 &= 1.0 - \hat{\lambda}_2^2, & \lambda_3 \lambda_2 &= 0.35 \\ \hat{\psi}_3 &= 1.0 - \hat{\lambda}_3^2, & \lambda_1 \lambda_3 &= 0.6 \end{aligned}$$

da cui la soluzione
$$\begin{aligned} \hat{\lambda}_1 &= 1.2, & \hat{\lambda}_2 &= 0.7, & \hat{\lambda}_3 &= 0.5, \\ \hat{\psi}_1 &= -0.44, & \hat{\psi}_2 &= 0.51, & \hat{\psi}_3 &= 0.75 \end{aligned}$$

Stime di tipo intuitivo possono condurre a soluzioni non accettabili anche se il modello è identificato esattamente!

Example 2.3. *Modello ad un fattore: $\text{Corr}(x)$*

Esempio 3 (tratto da Hardle e Simar 2003)

Si stimi il modello fattoriale ad un fattore per la matrice di correlazione relativa a valutazioni fornite da 40 clienti su 25 tipologie di auto per le variabili X_1 : economicità, X_2 : accessori, X_3 : deprezzamento

$$R = \begin{pmatrix} 1 & 0.975 & 0.613 \\ 0.975 & 1 & 0.620 \\ 0.613 & 0.620 & 1 \end{pmatrix}$$

Soluzione

$$\begin{pmatrix} 1 & r_{X_1 X_2} & r_{X_1 X_3} \\ r_{X_1 X_2} & 1 & r_{X_2 X_3} \\ r_{X_1 X_3} & r_{X_2 X_3} & 1 \end{pmatrix} = R = \begin{pmatrix} \hat{\lambda}_1^2 & \hat{\lambda}_1 \hat{\lambda}_2 & \hat{\lambda}_1 \hat{\lambda}_3 \\ & \hat{\lambda}_2^2 & \hat{\lambda}_2 \hat{\lambda}_3 \\ & & \hat{\lambda}_3^2 \end{pmatrix} + \begin{pmatrix} \hat{\psi}_1 & 0 & 0 \\ & \hat{\psi}_2 & 0 \\ & & \hat{\psi}_3 \end{pmatrix}$$

Da cui

$$\frac{r_{X_1 X_2} r_{X_1 X_3}}{r_{X_2 X_3}} = (0.982)^2 = \hat{\lambda}_1^2, \quad \frac{r_{X_1 X_2} r_{X_2 X_3}}{r_{X_1 X_3}} = (0.993)^2 = \hat{\lambda}_2^2, \quad \frac{r_{X_1 X_3} r_{X_2 X_3}}{r_{X_1 X_2}} = (0.624)^2 = \hat{\lambda}_3^2$$

e

$$\psi_1 = 1 - \hat{\lambda}_1^2 = 0.035 \quad \psi_2 = 0.014 \quad \psi_3 = 0.610$$

Le prime due comunali sono ≈ 1 . X_1 e X_2 sono ben spiegate dal I° fattore (economicità + accessori)

Example 2.4. Modello ad un fattore: $\text{Cov}(x)$

Example 11.1 Let $p = 3$ and $k = 1$, then $d = 0$ and

$$\Sigma = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \sigma_{13} \\ \sigma_{21} & \sigma_{22} & \sigma_{23} \\ \sigma_{31} & \sigma_{32} & \sigma_{33} \end{pmatrix} = \begin{pmatrix} q_1^2 + \psi_{11} & q_1 q_2 & q_1 q_3 \\ q_1 q_2 & q_2^2 + \psi_{22} & q_2 q_3 \\ q_1 q_3 & q_2 q_3 & q_3^2 + \psi_{33} \end{pmatrix}$$

with $\mathcal{Q} = \begin{pmatrix} q_1 \\ q_2 \\ q_3 \end{pmatrix}$ and $\Psi = \begin{pmatrix} \psi_{11} & 0 & 0 \\ 0 & \psi_{22} & 0 \\ 0 & 0 & \psi_{33} \end{pmatrix}$. Note that here the constraint (11.8) is automatically verified since $k = 1$. We have

$$q_1^2 = \frac{\sigma_{12}\sigma_{13}}{\sigma_{23}}; \quad q_2^2 = \frac{\sigma_{12}\sigma_{23}}{\sigma_{13}}; \quad q_3^2 = \frac{\sigma_{13}\sigma_{23}}{\sigma_{12}}$$

and

$$\psi_{11} = \sigma_{11} - q_1^2; \quad \psi_{22} = \sigma_{22} - q_2^2; \quad \psi_{33} = \sigma_{33} - q_3^2.$$

In this particular case ($k = 1$), the only rotation is defined by $\mathcal{G} = -1$, so the other solution for the loadings is provided by $-\mathcal{Q}$.

2.2 Vincoli e gradi di libertà

Numero di parametri del modello fattoriale $\Lambda\Lambda' + \Psi : pk + p$
Introduciamo ora il seguente vincolo (Vincolo 1):

$$\Lambda'\Psi^{-1}\Lambda = \text{diag}(b_1, \dots, b_k)$$

con $b_1 \geq \dots \geq b_k$

Il Vincolo 1 impone $k(k-1)/2$ restrizioni

Numero di parametri del modello fattoriale $\Lambda\Lambda' + \Psi$ dato il Vincolo 1: $pk + p - k(k-1)/2$

Come alternativa al Vincolo 1 si può considerare

Vincolo 2: $\Lambda'D^{-1}\Lambda = \text{diag}(c_1, \dots, c_k)$ con $c_1 \geq \dots \geq c_k$ e $D = \text{diag}(\sigma_{11}, \dots, \sigma_{pp})$

I *gradi di libertà* (= numero dei parametri “liberi”) sono dati dalla differenza tra i $p(p+1)/2$ parametri di Σ e il numero di parametri del modello fattoriale dato il Vincolo 1:

$$d = p(p+1)/2 - (pk + p - k(k-1)/2) = (p-k)^2/2 - (p+k)/2$$

- Se $d < 0$, allora il modello è indeterminato (ci sono infinite soluzioni)
- Se $d = 0$, allora la soluzione è unica (ma non necessariamente propria)
- $d > 0$, allora ci sono più equazioni che parametri: non c'è una soluzione esatta (ci si accontenta di una approssimazione)

Example 2.5. Modello indeterminato

Example 11.2 Suppose now $p = 2$ and $k = 1$, then $d < 0$ and

$$\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} = \begin{pmatrix} q_1^2 + \psi_{11} & q_1 q_2 \\ q_1 q_2 & q_2^2 + \psi_{22} \end{pmatrix}.$$

We have infinitely many solutions: for any α ($\rho < \alpha < 1$), a solution is provided by

$$q_1 = \alpha; \quad q_2 = \rho/\alpha; \quad \psi_{11} = 1 - \alpha^2; \quad \psi_{22} = 1 - (\rho/\alpha)^2.$$

2.3 Metodi di stima

Data $\hat{\Sigma} = S$ (oppure $= R$), vogliamo stimare $\hat{\Psi}$ e $\hat{\Lambda}$ in modo tale che $\hat{\Sigma} \approx \hat{\Lambda}\hat{\Lambda}' + \hat{\Psi}$ e sia rispettato il Vincolo 1 o 2

- Naïve (senza vincolo)
- Componenti principali
- Fattori principali
- Massima Verosimiglianza (richiede assunzione di Normalità per $\begin{smallmatrix} x \\ p \times 1 \end{smallmatrix}$)

Rotazione dei fattori:

Dopo aver stimato il modello fattoriale, può essere utile ruotare i pesi fattoriali $\hat{\Lambda}$ per ottenere $\hat{\Lambda}^* = \hat{\Lambda}A$ (con A matrice ortogonale), al fine di trovare configurazioni più facilmente interpretabili

Numero di fattori:

In pratica, dobbiamo anche determinare il valore di k

2.4 Metodo dei fattori principali

Si parte da $\hat{\Sigma} = \widehat{\text{Corr}}(x) = R$ per trovare $\hat{\Psi}$ e $\hat{\Lambda}$ in modo tale che $R - \hat{\Psi} \approx \hat{\Lambda}\hat{\Lambda}'$ e sia rispettato il Vincolo 2

- $R^* = R - \hat{\Psi}$ è detta *matrice di correlazione ridotta*
- $\{\text{Corr}(x)\}_{ii} = 1 = h_i^2 + \psi_i$, quindi se abbiamo a disposizione una stima iniziale \hat{h}_i^2 , allora $\{R^*\}_{ii} = 1 - \hat{\psi}_i = \hat{h}_i^2$
- $R^* = R - \hat{\Psi}$ è una matrice simmetrica, quindi la sua decomposizione spettrale è $R^* = VLV'$ con $L = \text{diag}(l_1, \dots, l_p)$ e $V = [v_1, \dots, v_p]$. Se i primi k autovalori l_1, \dots, l_k sono positivi e i rimanenti $p - k$ autovalori l_{k+1}, \dots, l_p prossimi a 0, allora

$$R^* \approx V_k L_k V_k'$$

dove V_k contiene le prime k colonne di V e $L_k = \text{diag}(l_1, \dots, l_k)$

- Segue $R^* = R - \hat{\Psi} \approx (V_k L_k^{1/2})(V_k L_k^{1/2})' \approx \hat{\Lambda} \hat{\Lambda}'$, quindi

$$\hat{\Lambda} \approx V_k L_k^{1/2}$$

Inizializzazione:

- Partire dalla stima R della matrice di correlazione $\mathbb{C}\text{orr}(x)$
- Calcolare la stima iniziale \hat{h}_i^2 della comunalità h_i^2 come
 - $\hat{h}_i^2 = \max_{j \neq i} |\widehat{\mathbb{C}\text{orr}}(x_i, x_j)|$
 - $\hat{h}_i^2 = 1 - \frac{1}{r^{ii}}$ dove $r^{ii} = \{R^{-1}\}_{ii}$, che equivale il coefficiente di determinazione lineare multiplo tra x_i e $\underset{(p-1) \times 1}{x_{-i}}$
- Ottenere la matrice di correlazione ridotta R^* da R ma sostituendo i valori 1 sulla diagonale con $\hat{h}_1^2, \dots, \hat{h}_p^2$

Algoritmo iterativo:

1. $R^* \leftarrow R$ e poi $\{R^*\}_{ii} \leftarrow \hat{h}_i^2, i = 1, \dots, p$
2. Ottenere la decomposizione spettrale $R^* = V L V'$
3. Fissare k e determinare V_k e L_k
4. Stimare Λ con $\hat{\Lambda} \approx V_k L_k^{1/2}$
5. Aggiornare $\hat{h}_i^2 \leftarrow \sum_{j=1}^k \hat{\lambda}_{ij}^2$ e $\{R^*\}_{ii} \leftarrow \hat{h}_i^2$
6. Ripetere i passi 2-5 fino a raggiungere convergenza

Output: $\hat{\Lambda}, \hat{h}_i^2$ e $\hat{\psi}_i = 1 - \hat{h}_i^2, i = 1, \dots, p$

Vincolo 2

$D = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}) = I$ perchè consideriamo la matrice di correlazione

Vincolo 2: $\hat{\Lambda}' \hat{D}^{-1} \hat{\Lambda} = \hat{\Lambda}' \hat{\Lambda} = \text{diag}(c_1, \dots, c_k)$ con $c_1 \geq \dots \geq c_k$

Quindi $\hat{\Lambda}$ soddisfa il Vincolo 2 perchè

$$\hat{\Lambda}' \hat{\Lambda} = (V_k L_k^{1/2})' (V_k L_k^{1/2}) = L_k = \text{diag}(l_1, \dots, l_k)$$

Casi di Heywood

Nella procedura di stima iterativa possono succedere casi di Heywood, ovvero $\hat{\psi}_i < 0$ oppure $\hat{\psi}_i > 1$

$\hat{\psi}_i < 0$ non ha senso perchè ψ_i è una varianza, e quindi > 0

$\hat{\psi}_i > 1$ non ha senso perchè $\mathbb{V}\text{ar}(x_i) = 1$ è quindi $\psi_i \leq 1$

2.5 Stima di massima verosimiglianza

Assunzione: x segue una distribuzione Normale p -variata $\mathcal{N}(\mu, \Sigma)$
 $p \times 1$ $p \times 1$ $p \times p$

Funzione di log-verosimiglianza:

$$\begin{aligned}\ell(X; \mu, \Sigma) &= -\frac{1}{2}n \log |2\pi\Sigma| - \frac{1}{2} \sum_{i=1}^n (x_i - \mu)\Sigma^{-1}(x_i - \mu)' \\ &= -\frac{1}{2}n \log |2\pi\Sigma| - \frac{1}{2}n \text{tr}(\Sigma^{-1}S) - \frac{1}{2}n(\bar{x} - \mu)\Sigma^{-1}(\bar{x} - \mu)'\end{aligned}$$

Sostituendo $\hat{\mu} = \bar{x}$

$$\ell(X; \hat{\mu}, \Sigma) = -\frac{n}{2} \left\{ \log |2\pi\Sigma| + \text{tr}(\Sigma^{-1}S) \right\}$$

e per $\Sigma = \Lambda\Lambda' + \Psi$ otteniamo

$$\ell(X; \hat{\mu}, \Lambda, \Psi) = -\frac{n}{2} \left\{ \log |2\pi(\Lambda\Lambda' + \Psi)| + \text{tr}[(\Lambda\Lambda' + \Psi)^{-1}S] \right\}$$

Massimizzare

$$\ell(X; \hat{\mu}, \Lambda, \Psi) = -\frac{n}{2} \left\{ \log |2\pi(\Lambda\Lambda' + \Psi)| + \text{tr}[(\Lambda\Lambda' + \Psi)^{-1}S] \right\}$$

rispetto a Ψ e Λ

Stima iterativa:

1. Per Ψ fissato, massimizza numericamente per Λ
 2. Per Λ fissato, massimizza numericamente per Ψ
- Implementata nella funzione R `factanal()`
 - Possiamo ottenere casi di Heywood

Example 2.6. Voto di $n = 202$ studenti maschi su $p = 6$ esami (variabili) Gaelic (non-math), English (non-math), History (non-math), Arithmetic (math), Algebra (math), Geometry (math).

	Gaelic	English	History	Arithmetic	Algebra	Geometry
R =	1.0	.439	.410	.288	.329	.248
		1.0	.351	.354	.320	.329
			1.0	.164	.190	.181
				1.0	.595	.470
					1.0	.464
						1.0

Stima di massima verosimiglianza con $k = 2$

Table 9.5			
Variable	Estimated factor loadings		Communalities \hat{h}_i^2
	F_1	F_2	
1. Gaelic	.553	.429	.490
2. English	.568	.288	.406
3. History	.392	.450	.356
4. Arithmetic	.740	-.273	.623
5. Algebra	.724	-.211	.569
6. Geometry	.595	-.132	.372

Stima di MV: $\hat{h}_1^2 = \hat{\lambda}_{11}^2 + \hat{\lambda}_{12}^2 = (0.553)^2 + (0.429)^2 \approx 0.490$

Primo fattore: intelligenza generale

Secondo fattore: abilità matematica vs abilità verbale

2.6 Rotazione dei pesi fattoriali

Per la rotazione dei pesi fattoriali $\Lambda_{p \times k}$, dobbiamo cercare una matrice ortogonale $A_{k \times k}$ ($A'A = AA' = I$) tale per cui i pesi fattoriali ruotati $\Lambda_{p \times k}^* = \Lambda_{p \times k} A_{k \times k}$ sono più facilmente interpretabili:

$$A_{2 \times 2} = \begin{bmatrix} \cos \phi & \sin \phi \\ -\sin \phi & \cos \phi \end{bmatrix} \text{ rotazione oraria per } k = 2$$

Questo non cambia la soluzione del modello, solo la sua descrizione. Situazione desiderata per i fini interpretativi:

- i pesi fattoriali sono tutti grandi e positivi o prossimi a 0 (con pochi valori intermedi)
- ogni variabile osservabile è legata in modo pesante al più ad un solo fattore

Per $k > 2$ il metodo *varimax* identifica la rotazione massimizzando un'opportuna funzione dei pesi fattoriali ruotati che misura la variabilità dei pesi.

Example 2.7. Riprendiamo l'esempio precedente:




Figure 9.1 Factor rotation for test scores.

Table 9.6			
Variable	Estimated rotated factor loadings		Communalities $\hat{h}_i^{*2} = \hat{h}_i^2$
	F_1^*	F_2^*	
1. Gaelic	.369	.594	.490
2. English	.433	.467	.406
3. History	.211	.558	.356
4. Arithmetic	.789	.001	.623
5. Algebra	.752	.054	.568
6. Geometry	.604	.083	.372

- *Primo fattore*: abilità matematica
- *Secondo fattore*: abilità verbale

2.7 Verifica d'ipotesi sul numero di fattori

Un vantaggio della stima di massima verosimiglianza è che permette un test di ipotesi sul numero di fattori

Ipotesi nulla H_0 : il modello fattoriale con k fattori è corretto

$$\Sigma = \underset{p \times k}{\Lambda} \underset{k \times p}{\Lambda'} + \Psi$$

Ipotesi alternativa H_1 : Σ è una matrice definitiva positiva diversa da quella specificata sotto l'ipotesi nulla

Rifiuto l'ipotesi nulla con un p -value $\leq 5\%$

Test sequenziali: parto da $k = 1$, se rifiuto proseguo con $k = 2, 3, \dots$ fino a quando fallisco di rifiutare l'ipotesi

Test rapporto di verosimiglianza

Siano $\hat{\Lambda}$ e $\hat{\Psi}$ le stime di massima verosimiglianza per il k specificato dall'ipotesi nulla
La statistica test rapporto di verosimiglianza è data da

$$T = -2 \log \left(\frac{\text{MV sotto } H_0}{\text{MV}} \right) = n \log \left(\frac{|\hat{\Lambda}\hat{\Lambda}' + \hat{\Psi}|}{|S|} \right)$$

e sotto H_0 segue asintoticamente una distribuzione

$$\chi^2_{\frac{1}{2}[(p-k)^2 - p - k]}$$

Il p -value del test si calcola come $\Pr(\chi^2_{\frac{1}{2}[(p-k)^2 - p - k]} > t)$ dove t è il valore osservato della statistica test

L'approssimazione χ^2 può essere migliorata utilizzando la statistica test con la correzione di Bartlett:

$$T_{Bartlett} = [(n-1) - (2p+4k+5)/6] \log \left(\frac{|\hat{\Lambda}\hat{\Lambda}' + \hat{\Psi}|}{|S|} \right)$$

2.8 Stima dei punteggi fattoriali

I punteggi fattoriali $\hat{f}_{k \times 1} = (\hat{f}_1, \dots, \hat{f}_k)'$ sono le “stime” delle variabili non osservabili $f_{k \times 1} = (f_1, \dots, f_k)'$

Metodo di Thompson (1951)

La distribuzione condizionata di $f_{k \times 1}$ dato $x_{p \times 1}$ è

$$\mathcal{N}(\Lambda' \Sigma^{-1} x, I - \Lambda' \Psi^{-1} \Lambda)$$

Per l' i -sima osservazione x_i (se standardizzata z_i),

$$\hat{f}_i = \hat{\Lambda}' S^{-1} x_i \quad (\hat{f}_i = \hat{\Lambda}' R^{-1} z_i)$$

Metodo di Bartlett (1937)

$$\hat{f}_i = (\hat{\Lambda}' \hat{\Psi}^{-1} \hat{\Lambda})^{-1} \hat{\Lambda}' \hat{\Psi}^{-1} x_i$$