Analisi Fattoriale - Applicazioni Analisi Esplorativa

Aldo Solari



1 Dati Esami

2 Stock-Price Data



Outline

1 Dati Esami

2 Stock-Price Data



Dati Esami

- Voto agli esami
- n = 202 studenti maschi
- p = 6

Variabili:

- Gaelic (non-math)
- English (non-math)
- History (non-math)
- Arithmetic (math)
- Algebra (math)
- Geometry (math)



Dati Esami: Correlazione

| | Gaelic | English | History | Arithmetic | Algebra | Geometry |
|----------------|--------|---------|---------|------------|---------|----------|
| $\mathbf{R} =$ | 1.0 | .439 | .410 | .288 | .329 | .248 |
| | | 1.0 | .351 | .354 | .320 | .329 |
| | | | 1.0 | .164 | .190 | .181 |
| | | | | 1.0 | .595 | .470 |
| | | | | | 1.0 | .464 |
| | | | | | | 1.0 |



Assunzioni

Se assumiamo che f e u hanno distribuzione congiunta Gaussiana con

$$f_{k\times 1} \sim \mathcal{N}_k(\underset{k\times 1}{0},\underset{k\times k}{I}), \quad u_{p\times 1} \sim \mathcal{N}_p(\underset{p\times 1}{0},\underset{p\times p}{\Psi})$$

allora x segue una distribuzione Gaussiana

$$\underset{p\times 1}{x} = \mu + \Lambda f + u \sim N_p(\underset{p\times 1}{\mu},\underset{p\times p}{\Lambda\Lambda'} + \underset{p\times p}{\Psi})$$

Si noti che abbiamo rilassato l'assunzione $\mathbb{E}(x)=0$, che equivale a $\mu=0$



Funzione di log-verosimiglianza

$$\ell(X; \mu, \Sigma) = -\frac{1}{2} n \log |2\pi\Sigma| - \frac{1}{2} \sum_{i=1}^{n} (x_i - \mu) \Sigma^{-1} (x_i - \mu)'$$
$$= -\frac{1}{2} n \log |2\pi\Sigma| - \frac{1}{2} n \operatorname{tr}(\Sigma^{-1}S) - \frac{1}{2} n (\bar{x} - \mu) \Sigma^{-1} (\bar{x} - \mu)'$$

Sostituendo $\hat{\mu} = \bar{x}$

$$\ell(X; \hat{\mu}, \Sigma) = -\frac{n}{2} \left\{ \log |2\pi\Sigma| + \operatorname{tr}(\Sigma^{-1}S) \right\}$$

e per $\Sigma = \Lambda \Lambda' + \Psi$ otteniamo

$$\ell(X; \hat{\mu}, \Lambda, \Psi) = -\frac{n}{2} \Big\{ \log |2\pi(\Lambda\Lambda' + \Psi)| + \text{tr}[(\Lambda\Lambda' + \Psi)^{-1}S] \Big\}$$



Stima di massima verosimiglianza

Massimizzare

$$\ell(X; \hat{\mu}, \Lambda, \Psi) = -\frac{n}{2} \Big\{ \log |2\pi(\Lambda\Lambda' + \Psi)| + \text{tr}[(\Lambda\Lambda' + \Psi)^{-1}S] \Big\}$$

rispetto a Ψ e Λ

Stima iterativa

- f 1 Per Ψ fissato, massimizza numericamente per Λ
- 2 Per Λ fissato, massimizza numericamente per Ψ

Commenti:

- Implementata nella funzione R factanal()
- Si possono ottenere casi di Heywood



Dati Esami: FA con k=2 e stima di MV

| Table 9.5 | | | | | |
|---------------|-------|-------------------|---------------|--|--|
| | | nated loadings | Communalities | | |
| Variable | F_1 | F_2 | h_i^2 | | |
| 1. Gaelic | .553 | .429 | .490 | | |
| 2. English | .568 | .288 | .406 | | |
| 3. History | .392 | .450 | .356 | | |
| 4. Arithmetic | .740 | 273 | .623 | | |
| 5. Algebra | .724 | 211 | .569 | | |
| 6. Geometry | .595 | 132 | .372 | | |

- \bullet Stima di MV: $\hat{h}_1^2=\hat{\lambda}_{11}^2+\hat{\lambda}_{12}^2=(0.553)^2+(0.429)^2\approx 0.490$
- Primo fattore: intelligenza generale
- Secondo fattore: abilità matematica vs abilità verbale



Rotazione dei pesi fattoriali

• Per la rotazione dei pesi fattoriali Λ , dobbiamo cercare una matrice ortogonale A (A'A=AA'=I) tale per cui i pesi fattoriali ruotati Λ * = Λ A sono più facilmente interpretabili

•
$$A_{2\times 2} = \begin{bmatrix} \cos\phi & \sin\phi \\ -\sin\phi & \cos\phi \end{bmatrix}$$
 rotazione oraria per $k=2$

- Questo non cambia la soluzione del modello, solo la sua descrizione
- Situazione desiderata per i fini interpretativi:
 - i pesi fattoriali sono tutti grandi e positivi o prossimi a 0 (con pochi valori intermedi)
 - ogni variabile osservabile è legata in modo pesante al più ad un solo fattore
- ullet Per k>2 il metodo *varimax* identifica la rotazione massimizzando un'opportuna funzione dei pesi fattoriali ruotati che misura la variabilità dei pesi



Dati Esami: rotazione dei pesi fattoriali




Figure 9.1 Factor rotation for test scores.

| Table 9.6 | | | | | |
|--|---|--|--|--|--|
| Variable | Estimated rotated factor loadings F_1^* F_2^* | | Communalities $\hat{h}_i^{*2} = \hat{h}_i^2$ | | |
| 1. Gaelic 2. English 3. History 4. Arithmetic 5. Algebra 6. Geometry | .369 .433 .211 .789 .752 .604 | .594 .467 .558 .001 .054 .083 | .490 .406 .356 .623 .568 .372 | | |

• Primo fattore: abilità matematica

• Secondo fattore: abilità verbale



Verifica d'ipotesi sul numero di fattori

- Un vantaggio della stima di massima verosimiglianza e che permette un test di ipotesi sul numero di fattori
- Ipotesi nulla H_0 : il modello fattoriale con k fattori è corretto

$$\Sigma = \Lambda \Lambda \Lambda' + \Psi$$

- Ipotesi alternativa H_1 : Σ è una matrice definitiva positiva diversa da quella specificata sotto l'ipotesi nulla
- Rifiuto l'ipotesi nulla con un p-value $\leq 5\%$
- Test sequenziali: parto da k=1, se rifiuto proseguo con $k=2,3,\ldots$ fino a quando fallisco di rifiutare l'ipotesi



Test rapporto di verosimiglianza

- Siano $\hat{\Lambda}$ e $\hat{\Psi}$ le stime di massima verosimiglianza per il k specificato dall'ipotesi nulla
- La statistica test rapporto di verosimiglianza è data da

$$T = -2\log\left(\frac{\text{MV sotto } H_0}{\text{MV}}\right) = n\log\left(\frac{|\hat{\Lambda}\hat{\Lambda}' + \hat{\Psi}|}{|S|}\right)$$

e sotto H_0 segue asintoticamente una distribuzione

$$\chi^2_{\frac{1}{2}[(p-k)^2-p-k]}$$

- Il p-value del test si calcola come $\Pr(\chi^2_{\frac{1}{2}[(p-k)^2-p-k]}>t)$ dove t è il valore osservato della statistica test
- L'approssimazione χ^2 può essere migliorata utilizzando la statistica test con la correzione di Bartlett:

$$T_{Bartlett} = \left[(n-1) - (2p + 4k + 5)/6 \right] \log \left(\frac{|\tilde{\Lambda}\tilde{\Lambda}' + \tilde{\Psi}|}{|S|} \right)$$

Distribuzione di f|x

Se assumiamo che f e u hanno distribuzione congiunta Gaussiana con

$$f_{k \times 1} \sim \mathcal{N}_k(\underset{k \times 1}{0}, \underset{k \times k}{I}), \quad u_{p \times 1} \sim \mathcal{N}_p(\underset{p \times 1}{0}, \underset{p \times p}{\Psi})$$

allora la loro combinazione lineare x ha distribuzione gaussiana

$$\underset{p \times 1}{x} = \Lambda f + u \sim N_p(\underset{p \times 1}{0}, \underset{p \times p}{\Lambda \Lambda'} + \underset{p \times p}{\Psi})$$

e la distribuzione di f condizionata ad x è anch'essa Gaussiana:

$$\int_{k \times 1} |x|_{p \times 1} \sim \mathcal{N}_k(\Lambda'(\Lambda \Lambda' + \Psi)^{-1}x, I - \Lambda'(\Lambda \Lambda' + \Psi)^{-1}\Lambda)$$



Punteggi fattoriali

- I punteggi fattoriali $\hat{f} = (\hat{f}_1, \dots, \hat{f}_k)'$ sono le "stime" delle variabili non osservabili $f = (f_1, \dots, f_k)'$
- Nel **metodo di Thompson** i punteggi fattoriali corrispondono alla (stima della) media di f|x:

$$\widehat{\mathbb{E}(f|x)} = \hat{\Lambda}'(\hat{\Lambda}\hat{\Lambda}' + \hat{\Psi})^{-1}x$$

In pratica si preferisce utilizzare S^{-1} (o R^{-1}) al posto di $(\hat{\Lambda}\hat{\Lambda}'+\hat{\Psi})^{-1}$

• Per l'i-sima osservazione x_i (centrata):

$$\hat{f}_i = \hat{\Lambda}' S^{-1} x_i$$

• Per l'i-sima osservazione standardizzata z_i

$$\hat{f}_i = \hat{\Lambda}' R^{-1} z_i$$



Punteggi fattoriali

 Nel metodo di Bartlett i punteggi fattoriali sono calcolati come soluzione al problema di minimizzazione

$$\hat{f} = \arg\min_{f} (x - \hat{\Lambda}f)'\hat{\Psi}^{-1}(x - \hat{\Lambda}f)$$

dove $\hat{\Lambda}$ e $\hat{\Psi}$ sono le stime di MV (che soddisfano il Vincolo 1)

• Per l'i-sima osservazione x_i (centrata):

$$\hat{f}_i = (\hat{\Lambda}' \hat{\Psi}^{-1} \hat{\Lambda})^{-1} \hat{\Lambda}' \hat{\Psi}^{-1} x_i$$

ullet Per l'i-sima osservazione standardizzata z_i

$$\hat{f}_i = (\hat{\Lambda}'\hat{\Psi}^{-1}\hat{\Lambda})^{-1}\hat{\Lambda}'\hat{\Psi}^{-1}z_i$$



Outline

1 Dati Esami

2 Stock-Price Data



| Table 8.4 Stock-Price Data (Weekly Rate Of Return) | | | | | |
|--|--------------------------------|--------------------------------|--------------------------------|--------------------------------|--------------------------------|
| Week | J P Morgan | Citibank | Wells Fargo | Royal Dutch Shell | Exxon Mobil |
| 1 2 3 | 0.01303 0.00849 -0.01792 | -0.00784 0.01669 -0.00864 | -0.00319 -0.00621 0.01004 | -0.04477 0.01196 0 | 0.00522 0.01349 -0.00614 |
| 4 5 6 | 0.02156 0.01082 0.01017 | -0.00349 0.00372 -0.01220 | 0.01744 -0.01013 -0.00838 | -0.02859 0.02919 0.01371 | -0.00695 0.04098 0.00299 |
| 7 8 | 0.01113 0.04848 | $0.02800 \\ -0.00515$ | 0.00807 0.01825 | 0.03054 0.00633 | 0.00323 0.00768 |
| 9 10 : | -0.03449 -0.00466 : | -0.01380 0.02099 : | -0.00805 -0.00608 : | -0.02990 -0.02039 : | −0.01081 −0.01267 ⋮ |
| 94 95 96 | 0.03732 0.02380 0.02568 | 0.03593 0.00311 0.05253 | 0.02528 -0.00688 0.04070 | 0.05819 0.01225 -0.03166 | 0.01697 0.02817 -0.01885 |
| 97 98 99 | -0.00606 0.02174 0.00337 | 0.00863 0.02296 -0.01531 | 0.00584 0.02920 -0.02382 | 0.04456 0.00844 -0.00167 | 0.03059 0.03193 -0.01723 |
| 100 101 102 | 0.00336 0.01701 0.01039 | 0.00290 0.00951 -0.00266 | -0.00305 0.01820 0.00443 | -0.00122 -0.01618 -0.00248 | -0.00970 -0.00756 -0.01645 |
| 103 | -0.01279 | -0.01437 | -0.01874 | -0.00498 | -0.01637 |



Stock-Price Data

- Rendimento (settimanale) di cinque titoli
- Gen 04 Dic 05
- n = 103
- p = 5

Variabili:

- JP Morgan (bank)
- Citibank (bank)
- Wells Fargo (bank)
- Royal Dutch Shell (oil)
- Exxon-Mobil (oil)



Stock-Price Data: correlazione

$$\bar{\mathbf{x}}' = [.0011, .0007, .0016, .0040, .0040]$$

$$\mathbf{R} = \begin{bmatrix} 1.000 & .632 & .511 & .115 & .155 \\ .632 & 1.000 & .574 & .322 & .213 \\ .511 & .574 & 1.000 & .183 & .146 \\ .115 & .322 & .183 & 1.000 & .683 \\ .155 & .213 & .146 & .683 & 1.000 \end{bmatrix}$$

Stock-Price Data: stima di MV

| Table 9.8 | | | | | |
|--|---|-------------------------------------|---|---------------------------------------|---|
| Variable | Maximum likelihood estimates of factor loadings F_1 F_2 | | Rotated estimated factor loadings F_1^* F_2^* | | Specific variances $\hat{\psi}_i^2 = 1 - \hat{h}_i^2$ |
| J P Morgan Citibank Wells Fargo Royal Dutch Shell ExxonMobil | .115 .322 .182 1.000 .683 | .755 .788 .652 000 .032 | .763 .821 .669 .118 .113 | .024 .227 .104 (.993 .675 | .42 .27 .54 .00 .53 |
| Cumulative proportion of total sample variance explained | .323 | .647 | .346 | .647 | |

- Primo fattore (ruotato): bank
- Secondo fattore (ruotato): oil
- Proporzione di varianza spiegata dal j-mo fattore $=\frac{\sum_{i=1}^p\hat{\lambda}_{ij}^2}{p}$



Stock-Price Data: residui

Massima Verosimiglianza

$$\mathbf{R} - \hat{\mathbf{L}}\hat{\mathbf{L}}' - \hat{\mathbf{\Psi}} = \begin{bmatrix} 0 & .001 & -.002 & .000 & .052 \\ .001 & 0 & .002 & .000 & -.033 \\ -.002 & .002 & 0 & .000 & .001 \\ .000 & .000 & .000 & 0 & .000 \\ .052 & -.033 & .001 & .000 & 0 \end{bmatrix}$$



Stock-Price Data: test di k=2

Ipotesi nulla

$$H_0: \Sigma = \Lambda \Lambda' + \Psi \quad (k=2)$$

Statistica test

$$n \ln \frac{|\hat{\Lambda}\hat{\Lambda}' + \hat{\Psi}_z|}{|R|} = n \ln \frac{0.17898}{0.17519} = n \ln 1.0216$$

p-value

$$\mathbb{P}(\chi_1^2 > n \ln(1.0216)) \approx 0.138 > 5\%$$

(p-value = 0.15 utilizzando la correzione di Bartlett)



Stock-Price Data: punteggi fattoriali

Decomposizione di R

$$\hat{\mathbf{L}}_{\mathbf{z}}^{*} = \begin{bmatrix} .763 & .024 \\ .821 & .227 \\ .669 & .104 \\ .118 & .993 \\ .113 & .675 \end{bmatrix} \text{ and } \hat{\boldsymbol{\Psi}}_{\mathbf{z}} = \begin{bmatrix} .42 & 0 & 0 & 0 & 0 \\ 0 & .27 & 0 & 0 & 0 \\ 0 & 0 & .54 & 0 & 0 \\ 0 & 0 & 0 & .00 & 0 \\ 0 & 0 & 0 & 0 & .53 \end{bmatrix}$$

Una osservazione

$$\mathbf{z}' = [.50, -1.40, -.20, -.70, 1.40]$$

Metodo di Bartlett

$$\hat{\mathbf{f}} = (\hat{\mathbf{L}}_{\mathbf{z}}^{*}, \hat{\mathbf{\Psi}}_{\mathbf{z}}^{-1} \hat{\mathbf{L}}_{\mathbf{z}}^{*})^{-1} \hat{\mathbf{L}}_{\mathbf{z}}^{*}, \hat{\mathbf{\Psi}}_{\mathbf{z}}^{-1} \mathbf{z} = \begin{bmatrix} -.61 \\ -.61 \end{bmatrix}$$

Metodo di Thompson

$$\hat{\mathbf{f}} = \hat{\mathbf{L}}_{\mathbf{z}}^{*} \mathbf{R}^{-1} \mathbf{z} = \begin{bmatrix} .331 & .526 & .221 & -.137 & .011 \\ -.040 & -.063 & -.026 & 1.023 & -.001 \end{bmatrix} \begin{bmatrix} .50 \\ -1.40 \\ -.20 \\ -.70 \\ 1.40 \end{bmatrix} = \begin{bmatrix} .50 \\ -.64 \end{bmatrix}$$



Stock-Price Data: punteggi fattoriali




Figure 9.4 Factor scores using (9-58) for factors 1 and 2 of the stock-price data (maximum likelihood estimates of the factor loadings).

