

7 Febbraio 2020 - Analisi Esplorativa (Analisi Statistica Multivariata)

Cognome:

Nome:

Matricola:

Prova scritta - fila A

Si svolgano gli esercizi riportando il risultato dove indicato. Durata: 90 minuti

Esercizio 1 (Punti 2)

Si dimostri che $J_{n \times n} = I - H$ è una matrice idempotente, dove $I_{n \times n}$ è la matrice identità e $H_{n \times n}$ è la matrice di centramento, giustificando tutti i passaggi.

Esercizio 2 (Punti 4)

Si consideri la seguente matrice $X_{n \times p} = \begin{bmatrix} 3 & 1 & 0 \\ 6 & 4 & 6 \\ 4 & 2 & 2 \\ 7 & 0 & 3 \\ 5 & 3 & 4 \end{bmatrix}$

- (Punti 1) Calcolare la matrice dei dati centrati \tilde{X}
- (Punti 2) Verificare che le colonne di \tilde{X} sono linearmente dipendenti, determinando un vettore non-nullo $c_{p \times 1}$ tale che $\tilde{X}c = 0_{n \times 1}$
- (Punti 1) Calcolare la matrice di varianze e covarianze S e la varianza generalizzata

$$\tilde{X} = \begin{bmatrix} \\ \\ \\ \\ \end{bmatrix} \quad c = \begin{bmatrix} \\ \end{bmatrix} \quad S = \begin{bmatrix} & \\ & \end{bmatrix} \quad \det(S) =$$

Esercizio 3 (Punti 4)

Alla matrice di varianze/covarianze $S_{p \times p}$ sono associati i seguenti autovalori $\lambda_1 = 6, \lambda_2 = 4$ e autovettori normalizzati $v_1 = \begin{bmatrix} 1/\sqrt{5} \\ 2/\sqrt{5} \end{bmatrix}, v_2 = \begin{bmatrix} 2/\sqrt{5} \\ -1/\sqrt{5} \end{bmatrix}$.

- a. (Punti 2) Riportare la matrice di correlazione $R_{p \times p}$ e la matrice $S^{2/3}_{p \times p}$ (arrotondando i risultati al secondo decimale):

$R = \begin{bmatrix} & \\ & \end{bmatrix} \quad S^{2/3} = \begin{bmatrix} & \\ & \end{bmatrix}$

- b. (Punti 2) Calcolare la correlazione tra la prima colonna \tilde{x}_1 di $\tilde{X}_{n \times p}$ e i punteggi y_1 della prima componente principale, arrotondando il risultato al secondo decimale:

--

Esercizio 4 (Punti 3)

Si consideri la seguente matrice di distanza:

	1	2	3	4
1	0			
2	3	0		
3	7	9	0	
4	8	6	5	0

- a. (Punti 2) Si utilizzi il metodo gerarchico agglomerativo con il legame completo, riportando ad ogni passo dell'algoritmo la matrice delle distanze tra gruppi

<table style="width: 100%; border-collapse: collapse;"> <tr> <td style="width: 10%;"></td> <td style="width: 10%; border-bottom: 1px solid black;"></td> <td style="width: 10%; border-bottom: 1px solid black;"></td> <td style="width: 10%; border-bottom: 1px solid black;"></td> <td style="width: 10%; border-bottom: 1px solid black;"></td> <td style="width: 10%; border-bottom: 1px solid black;"></td> <td style="width: 10%; border-bottom: 1px solid black;"></td> <td style="width: 10%; border-bottom: 1px solid black;"></td> </tr> <tr> <td style="border-right: 1px solid black; padding-right: 10px;">passo 1)</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">0</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">0</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">0</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> </tr> <tr> <td style="border-right: 1px solid black; padding-right: 10px;"></td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">0</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">0</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">0</td> </tr> <tr> <td style="border-right: 1px solid black; padding-right: 10px;"></td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">0</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">0</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> </tr> </table>									passo 1)	0	0	0	0	0	0		0	0	<table style="width: 100%; border-collapse: collapse;"> <tr> <td style="width: 10%;"></td> <td style="width: 10%; border-bottom: 1px solid black;"></td> <td style="width: 10%; border-bottom: 1px solid black;"></td> <td style="width: 10%; border-bottom: 1px solid black;"></td> <td style="width: 10%; border-bottom: 1px solid black;"></td> <td style="width: 10%; border-bottom: 1px solid black;"></td> <td style="width: 10%; border-bottom: 1px solid black;"></td> <td style="width: 10%; border-bottom: 1px solid black;"></td> </tr> <tr> <td style="border-right: 1px solid black; padding-right: 10px;">passo 2)</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">0</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">0</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">0</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> </tr> <tr> <td style="border-right: 1px solid black; padding-right: 10px;"></td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">0</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">0</td> <td style="border-right: 1px solid black; padding-right: 10px;">.....</td> <td style="border-right: 1px solid black; padding-right: 10px;">0</td> </tr> </table>									passo 2)	0	0	0	0	0	0
passo 1)	0	0	0																																																		
	0	0	0																																																		
	0	0																																																		
passo 2)	0	0	0																																																		
	0	0	0																																																		

- b. (Punti 1) Riportare il dendrogramma corrispondente al punto a.

Esercizio 5 (Punti 9)

Si consideri la seguente matrice di correlazione calcolata sulla base di $n = 50$ osservazioni:

	Murder	Assault	UrbanPop	Rape
Murder	1.0	0.8	0.1	0.6
Assault	0.8	1.0	0.3	0.7
UrbanPop	0.1	0.3	1.0	0.4
Rape	0.6	0.7	0.4	1.0

- a. (Punti 1) Sulla base della matrice di correlazione, si stimi il modello fattoriale con $k = 1$ fattore utilizzando il metodo della massima verosimiglianza senza effettuare alcuna rotazione. Arrotondando al terzo decimale, si riportino le stime dei pesi fattoriali:

$\hat{\lambda}_1 = \dots\dots\dots$ $\hat{\lambda}_2 = \dots\dots\dots$ $\hat{\lambda}_3 = \dots\dots\dots$ $\hat{\lambda}_4 = \dots\dots\dots$

- b. (Punti 2) Si determini il punteggio fattoriale con il metodo di Thompson (arrotondando alla quarta cifra decimale) per l'unità statistica "Arizona" sapendo che i suoi valori nelle quattro variabili standardizzate sono

	Murder	Assault	UrbanPop	Rape
Arizona	1.2426	0.7828	-0.5209	-0.0034

- c. (Punti 2) Si riporti la stima delle comunalità per le quattro variabili, arrotondando al secondo decimale. Indicare quale variabile è spiegata meglio dal modello, motivando la risposta.

	Murder	Assault	UrbanPop	Rape
Comunalità				
Variabile spiegata meglio:				

- d. (Punti 1) Si valuti l'opportunità di stimare un modello a 2 fattori, motivando la risposta.

- e. (Punti 3) Si calcolino le correlazioni tra la j -sima variabile standardizzata z_j e la k -sima componente principale y_k per $j = 1, \dots, 4$ e $k = 1, \dots, 4$, riportandole nella seguente tabella (arrotondando al secondo decimale).

	y_1	y_2	y_3	y_4
z_1				
z_2				
z_3				
z_4				

Potrebbe tornare utile sapere che le covarianze tra variabili standardizzate e componenti principali sono date dalla matrice

$$\frac{1}{n} Z'Y$$

dove $Y = ZV$ è la matrice dei punteggi delle componenti principali e $R = V\Lambda V'$ è la matrice di correlazione.

Esercizio 6 (Punti 4)

Si consideri il dataset **swiss** presente nella libreria **datasets**, che contiene $n = 47$ unità statistiche (province) relative alle seguenti 6 variabili:

- *Fertility* : common standardized fertility measure
- *Agriculture* : % of males involved in agriculture as occupation
- *Examination* : % draftees receiving highest mark on army examination
- *Education* : % education beyond primary school for draftees
- *Catholic* : % catholic (as opposed to protestant)
- *Infant.Mortality* : live births who live less than 1 year

- a. (Punti 2) Per ciascuna unità statistica, si calcoli la distanza di Mahalanobis dal baricentro, e si riportino i valori delle distanze superiori a 3.35 (arrotondando al terzo decimale) con i rispettivi nomi delle unità (province)

--

- b. (Punti 2) Standardizzare i dati **swiss**, e utilizzare l'algoritmo delle K -medie (**algorithm = Hartigan-Wong**) per $K = 2, 4, 6$, inizializzando i centroidi con le osservazioni di riga $1, 2, \dots, K$. Riportare per ciascun valore di K il rispettivo valore dell'indice Calinski and Harabasz (arrotondando al terzo decimale).

K	2	4	6
Indice CH