

Cognome: ..... Nome: ..... Matricola: .....

Tipologia d'esame: ☐ 12 CFU ☐ 15 CFU

## Prova scritta di ASM 12CFU e 15CFU - Modulo Analisi Esplorativa del 11.07.2017

La durata della prova è di 60 minuti.

Si svolgono gli esercizi 1, 2 e 3 riportando il risultato dove indicato.

### Esercizio 1 (Punti: 8)

**1.a)** Siano date due unità statistiche  $u'_1 = (1, 1)$  e  $u'_2 = (2, 3)$ . Calcolare

Distanza Euclidea  $d_2(u_1, u_2) = \dots$

Distanza di Manhattan  $d_1(u_1, u_2) = \dots$

Distanza di Lagrange  $d_\infty(u_1, u_2) = \dots$

Distanza di Canberra  $d_C(u_1, u_2) = \dots$

**1.b)** Si consideri la seguente matrice di distanze relativa a tre unità statistiche  $u_1, u_2$  e  $u_3$ :

$D =$   
 $3 \times 3$

	$u_1$	$u_2$	$u_3$
$u_1$	0		
$u_2$	7	0	
$u_3$	6	5	0

Se utilizziamo un algoritmo gerarchico agglomerativo, le unità  $u_1$  e  $u_2$  vengono messe assieme nel gruppo  $(u_1, u_2)$ . Aggiornare la matrice delle distanze utilizzando il metodo del legame singolo:

	$(u_1, u_2)$	$(u_3)$
$(u_1, u_2)$	0	
$(u_3)$	...	0

Aggiornare la matrice delle distanze utilizzando il metodo del legame medio:

	$(u_1, u_2)$	$(u_3)$
$(u_1, u_2)$	0	
$(u_3)$	...	0

**1.c)** Si consideri la seguente decomposizione della distanza totale  $T$  in distanza entro i gruppi  $W$  e tra i gruppi  $B$  per tre unità statistiche  $u_1, u_2$  e  $u_3$  raggruppate in due gruppi  $G_1$  e  $G_2$ :

$G_1, G_2$	$W$	$B$	$T$
$(u_1), (u_2, u_3)$	2	...	12
$(u_1, u_2), (u_3)$	...	10.5	12
$(u_1, u_3), (u_2)$	...	8.5	...

Completare la tabella con le informazioni mancanti.

Qual è il raggruppamento ottimale?  $G_1 = \dots$ ,  $G_2 = \dots$

## Esercizio 2 (Punti: 8)

Data la matrice di varianze/covarianze  $S_{3 \times 3} = \begin{bmatrix} 4 & 3 & 1 \\ 3 & 9 & 2 \\ 1 & 2 & 1 \end{bmatrix}$

**2.a)** Riportare

Varianza totale = ..... e generalizzata = .....

L'indice di variabilità relativo (arrotondare al secondo decimale) = .....

**2.b)** Determinare la matrice di correlazione  $R_{3 \times 3} = \begin{bmatrix} \dots & \dots & \dots \\ \dots & \dots & \dots \\ \dots & \dots & \dots \end{bmatrix}$ .

**2.c)** Determinare, arrotondando al secondo decimale,  $S_{p \times p}^{1/2} = \begin{bmatrix} \dots & \dots \\ \dots & \dots \end{bmatrix}$

**2.d)** Calcolare la correlazione tra la seconda colonna  $\tilde{x}_2$  di  $\tilde{X}_{n \times p}$  e i punteggi  $y_2$  della seconda componente principale, arrotondando al secondo decimale.


= .....

```
## [1] 14
## [1] 14
## [1] 0.39
##      [,1]      [,2]      [,3]
## [1,]  1.0 0.5000000 0.5000000
## [2,]  0.5 1.0000000 0.6666667
## [3,]  0.5 0.6666667 1.0000000
##      [,1] [,2] [,3]
## [1,] 1.89  0.6 0.26
## [2,] 0.60  2.9 0.50
## [3,] 0.26  0.5 0.83
## [1] -0.23
```

## Esercizio 3 (Punti: 9)

Importare il logo di R nella matrice  $\tilde{X}_{n \times p}$  con  $n = 100$  e  $p = 76$  tramite i comandi

```
rm(list=ls())
library(png)
logo <- readPNG(system.file("img", "Rlogo.png", package="png"))
X <- t(logo[, ,1])
n = nrow(X)
p = ncol(X)
# visualizza immagine
image(X, col=gray(0:255/255), asp=p/n)
```



**3.a)** Effettuare l'analisi delle componenti principali dei dati centrati  $\tilde{X}$  (utilizzare il comando `princomp`), riportando il numero delle componenti necessarie per spiegare almeno 85% della variabilità:

NUMERO DI COMPONENTI = ..... PROPORZIONE DI VARIABILITA' SPIEGATA = .....

```
## Comp.8
##      8

##      Comp.8
## 0.8636509
```

**3.b)** Dopo aver calcolato la matrice dei punteggi  $Y = \tilde{X} V$  e la matrice dei pesi  $V$ , ottenere la migliore approssimazione per  $\tilde{X}$  di rango  $q$ ,  $A_q = Y_q V_q'$ , con  $q$  determinato al punto precedente ( $q$  = numero delle componenti necessarie per spiegare almeno 85% della variabilità). Costruire l'immagine compressa  $C = A_q + \frac{1}{n \times p} \bar{x}$ , assicurandosi che tutti gli elementi di  $C$  siano compresi tra 0 e 1. Riportare infine i 5 numeri di sintesi per l'immagine compressa:

MEDIA = ...

MEDIANA = ...

1 QUARTILE = ...

3 QUARTILE = ...

Min = ...

Max = ...

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.00000 0.03987 0.31959 0.30156 0.50744 0.98670
```

**3.c)** Confrontare l'immagine compressa con l'immagine originale calcolando il fattore di riduzione in termini di pixels e bytes (utilizzando il comando `object.size`)

FATTORE DI RIDUZIONE (PIXELS) = ...

FATTORE DI RIDUZIONE (BYTES) = ...

```
## [1] 5.12  
## 4.4 bytes
```